

American Sign Language Understanding

André Alves - 89334

Miguel Mota - 89331



universidade de aveiro
theoria poesis praxis



Introdução

- Dados
- Algoritmos:
 - Regressão Logística
 - Rede Neural
 - Rede Neural Convolucional
- K-Fold Cross Validation
- Matriz de Confusão



Dados

- Duas base de dados
- Imagens 28 x 28 pixels (GrayScale)
- 24 Classes

A	B	C	D	E	F	G	H	I	J	K	L	M
1126	1010	1144	1196	957	1204	1090	1013	1162	0	1114	1241	1055
N	O	P	Q	R	S	T	U	V	W	X	Y	Z
1151	1196	1088	1279	1294	1199	1186	1161	1082	1225	1164	1118	00



Dados de Treino

Total: 27455 imagens



A	B	C	D	E	F	G	H	I	J	K	L	M
331	432	310	245	498	247	348	436	288	0	331	209	394
N	O	P	Q	R	S	T	U	V	W	X	Y	Z
291	246	347	164	144	246	248	266	346	206	267	332	00



Dados de Teste

Total: 7172 imagens

Algoritmos

Problema de Classificação Não-Linear



Regressão Logística

- Valores não esperados
- Pouco eficiente
- Duração 4 horas para cross-validation de 1/20 imagens




Não é adequado para um problema complexo não-linear



Rede Neural

- Comparado ao algoritmo de regressão logística:
 - Mais eficiente
 - Melhores resultados - 80% de precisão




Não era possível executar com o GPU com a biblioteca SK-Learn

Rede Neural Convolucional (CNN)

Como funciona?

- 3 Layers:
 - Input
 - **Hidden Layers**
 - A. Convolutional Layer
 - B. Pooling
 - C. Dropout
 - D. Flatten
 - E. Dense
 - Output





12	20	30	0
8	12	2	0
34	70	37	4
112	100	25	12

2×2 Max-Pool

20	30
112	37

B

Exemplo de uma arquitetura de CNN:





Rede Neural Convolucional (CNN)

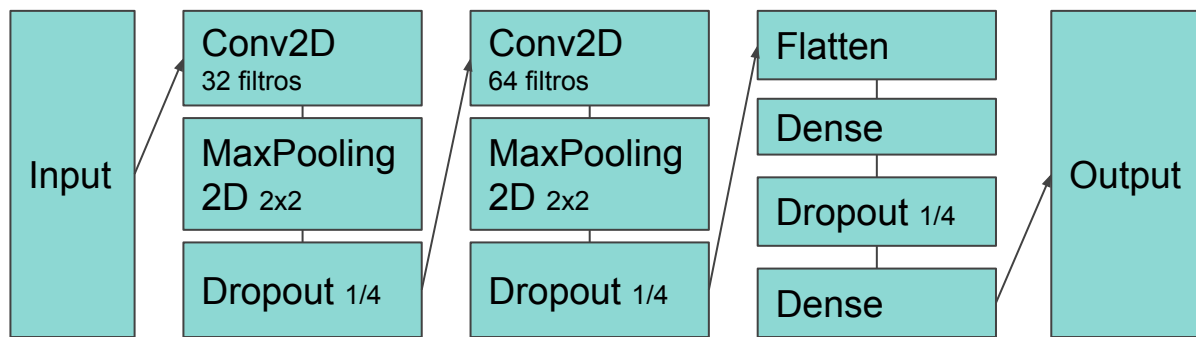
Pré-Processamento de Dados

- Sem normalização das features:
 - 2 % de precisão
 - Normalização das features:
 - $z = \frac{x - \mu}{S}$
 - 92 % de precisão
- ✓ Dados não normalizados faz com que o modelo não convirja no mesmo tempo se fosse com os dados normalizados.




Rede Neural Convolucional (CNN)

Arquitetura



Epochs: 10
BatchSize : 1000




Accuracy: 93%
Loss : 23%



Rede Neural Convolucional (CNN)

K-Fold Cross Validation

- 5 Splits



Dropout 0.2, Pooling 2x2 e 32
filtros

Test Score:	0.96
Média Validation Score:	1.00
Média Train Score:	0.99

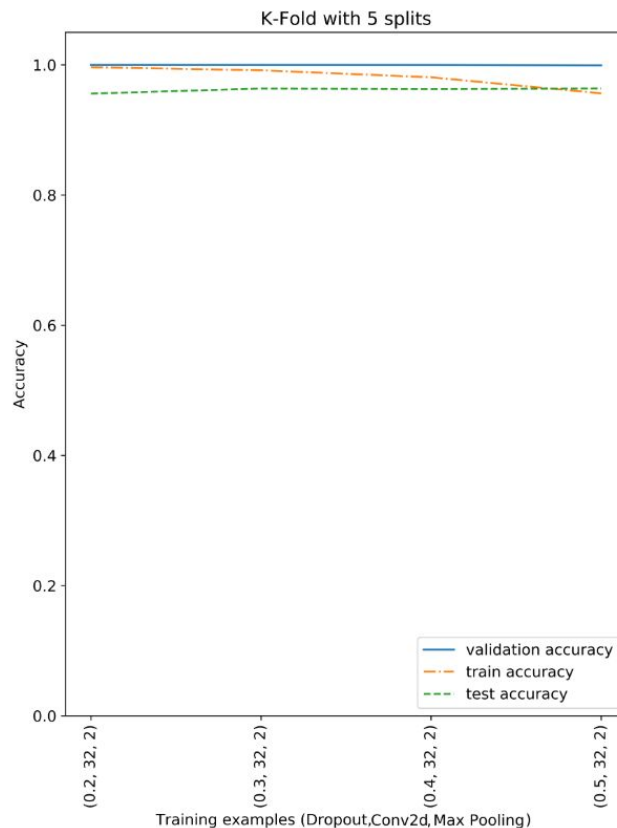
- 96% ainda é um valor relativamente baixo para um problema de 24 classes.
- **Overfit**



Rede Neural Convolucional (CNN)

K-Fold Cross Validation

- Para combater o **overfit**, mudou-se o **rate do dropout**, na qual é um hiper parâmetro regularizador que ajuda a prevenir o overfitting.
- Pelo gráfico, é visível a diminuição do overfitting com o aumento de rate do dropout, contudo ainda não é um valor desejável.





Rede Neural Convolucional (CNN)

K-Fold Cross Validation - Compreensão do modelo

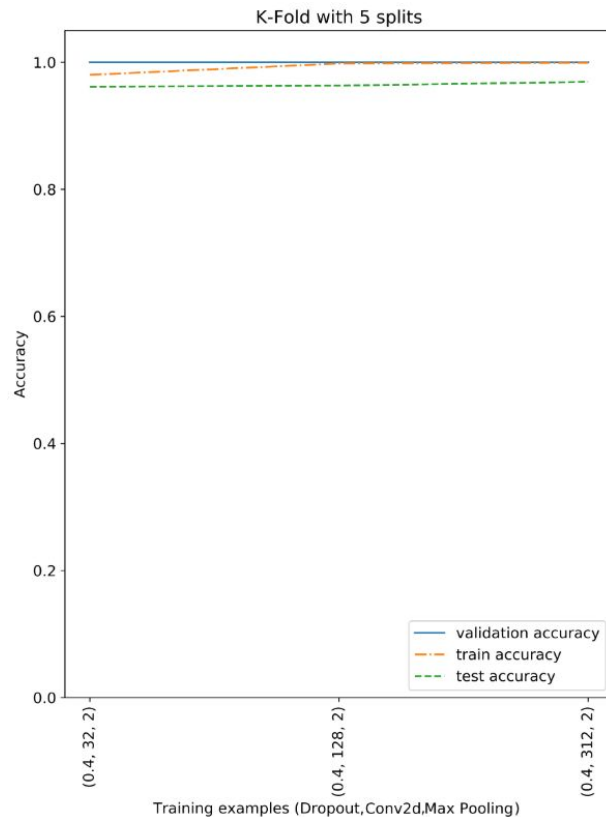
- 181 classificações erradas em 7172 imagens, com 11 classes a serem mal classificadas.
- As letras G,T e N responsáveis por 31,45 e 30 respetivamente.
- 3 classes são responsáveis por cerca de 60% das classificações erradas.
- As classes mais escolhidas erradamente foram H,M e X.



Rede Neural Convolucional (CNN)

K-Fold Cross Validation

- O train accuracy aumentou muito.
- Embora ainda exista overfitting, a melhoria do resultado na parte de treino, comprova que o **número de filtros** na camada Conv2d é sensível na performance do modelo.






Rede Neural Convolucional (CNN)

K-Fold Cross Validation

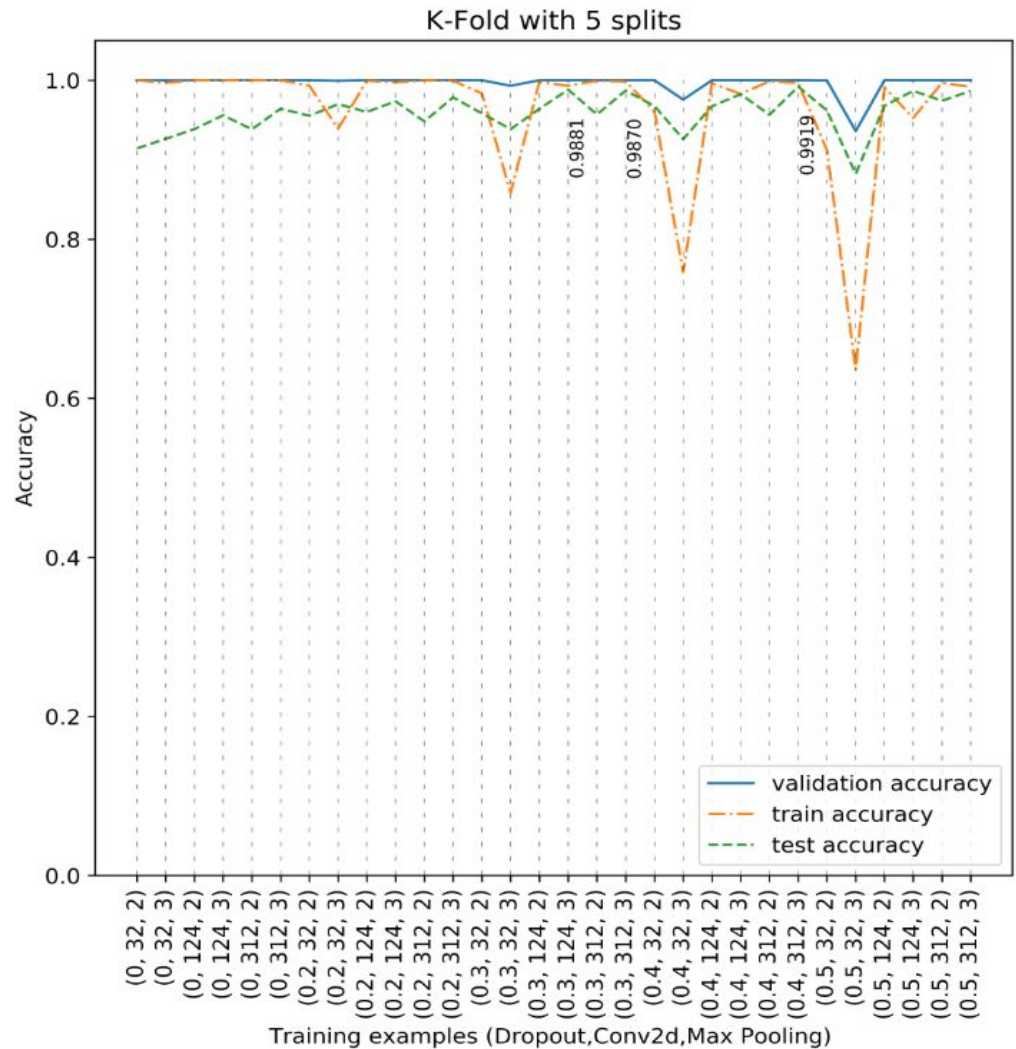
- Pooling com um tamanho de 2×2 , pode ser um fator causador de overfitting, por estar a guardar apenas o valor máximo a cada 2 píxeis. Se passarmos para 3×3 , torna-se uma camada mais **regularizadora**.



Test Score	0.9905
Media Validation Score	1.0
Media Train Score	0.9983

Melhores Modelos

- Test Acc. : 0.9919
 - (0.4, 312, 3)
- Test Acc. : 0.9870
 - (0.3, 312, 3)
- Test Acc. : 0.9881
 - (0.3, 124, 3)







Rede Neural Convolucional (CNN)

Última variação de hiperparâmetros

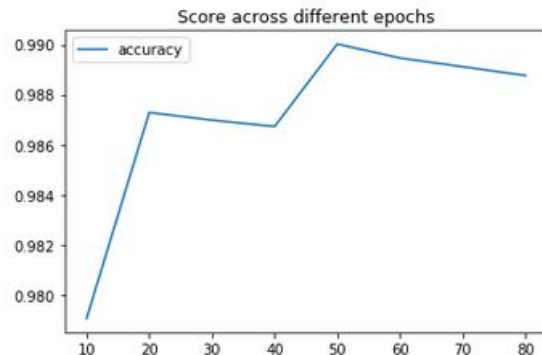
- Por fim, tentou-se apenas variar as épocas para os três melhores modelos, onde se pode ver que 40 épocas é o melhor valor para o melhor modelo.



Melhor Modelo




Segundo Melhor Modelo





Terceiro Melhor Modelo

Matriz de confusão





Melhorias



K

H

Y



Conclusão

- Compreensão do modelo, como:
 - a sua performance;
 - seus parâmetros;
 - camadas;
- Aprendizagem do uso de métodos estatísticos e qual a sua importância.